

Dossiê de Modelos & Custos de Tokens

Análise Comparativa: OpenCode Go vs. Google Antigravity Ecosystem

NEXUS SWARM HARNESS

**Dica Estratégica de Otimização:** O ecossistema foi configurado para utilizar o **LongCat (\$0.00)** como Maestro Central e os modelos **Flash (\$0.15/1M)** para as tarefas operacionais. Com o cabeçalho `x-opencode-session = "swarm-persistent-cache"` ativo, as chamadas recorrentes recebem **98% de desconto** no prompt cache (\$0.003/1M), garantindo que a cota dure o mês inteiro com chamadas contínuas.

1. OpenCode Go: Núcleo Gratuito & Ilimitado

Modelos sem cobrança de tokens e sem consumo do teto mensal da assinatura Go:

MODELO	ENTRADA / 1M	SAÍDA / 1M	CONTEXTO	CAPACIDADES & DESTAQUES
longcat-2.5-preview-free Zero Custo	\$0.00	\$0.00	128.000 (128k)	Thinking Tokens Nativos , Tool Use. Raciocínio profundo ideal para o Maestro Central. Cota ILIMITADA.

2. OpenCode Go: Núcleo Flash de Alta Eficiência

Modelos de frações de centavo recomendados para as missões diárias em paralelo do Enxame:

MODELO	ENTRADA / 1M	SAÍDA / 1M	PROMPT CACHE	CONTEXTO	COTA GO	PAPEL NO ENXAME
deepseek-v4-flash Flash	\$0.15	\$0.60	\$0.003	128k	\$120 / mês	@web-architect
deepseek-v4.1-flash Flash	\$0.15	\$0.60	\$0.003	128k	\$120 / mês	Programação/Lógica
glm-5.3-flash Flash	\$0.15	\$0.50	\$0.003	64k	\$180 / mês	@marketing-strategist
qwen3.8-flash Flash	\$0.15	\$0.47	\$0.003	128k	\$90 / mês	@prompt-artisan
minimax-m3 Flash	\$0.30	\$1.20	\$0.006	128k	\$180 / mês	@instagram-architect

3. OpenCode Go: Modelos Pro & Multimodais (Visão)

Modelos robustos para tarefas pontuais de alta complexidade ou leitura de imagens:

MODELO	ENTRADA / 1M	SAÍDA / 1M	CONTEXTO	SUPORTA IMAGEM?	COTA GO	JANELA 5H
kimi-k3 Vision	\$3.00	\$15.00	200.000	SIM (Vision 👁)	\$60 / mês	~\$12 / 5h
kimi-k2.7-code Vision	\$1.00	\$4.00	128.000	SIM (Vision 👁)	\$90 / mês	~\$18 / 5h
deepseek-v4-pro Pro	\$0.27	\$1.10	128.000	Não	\$120 / mês	~\$24 / 5h
glm-5.3 Pro	\$1.00	\$3.00	128.000	Não	\$120 / mês	~\$24 / 5h
qwen3.8-max Pro	\$1.60	\$6.40	128.000	Não	\$90 / mês	~\$18 / 5h

Dossiê de Modelos & Custos de Tokens

4. Google Antigravity: Ecossistema Gemini (Google AI / Vertex AI)

Plataforma agêntica oficial da Google DeepMind. O uso no app desktop é **incluso na conta Google conectada**, com as seguintes taxas da API:

MODELO	ENTRADA / 1M	SAÍDA / 1M	JANELA CONTEXTO	PROMPT CACHE	ESPECIALIDADE AGÊNTICA
Gemini 2.5 Flash Lite Lite	\$0.0375	\$0.15	1.000.000 (1M)	\$0.009	Latência ultrabaixa, micro-tarefas e loops rápidos.
Gemini 2.5 Flash Flash	\$0.0750	\$0.30	1.000.000 (1M)	\$0.018	Equilíbrio perfeito: 1M tokens, multimodal nativo.
Gemini 2.5 Pro Pro	\$1.2500	\$5.00	2.000.000 (2M)	\$0.312	Raciocínio profundo, arquiteturas e refatorações complexas.

5. Matriz de Decisão: Qual Ambiente Utilizar?

Guia rápido para escolher a ferramenta certa e maximizar a produtividade sem desperdício:

NECESSIDADE / CASO DE USO	AMBIENTE RECOMENDADO	MODELO INDICADO	CUSTO ESTIMADO
Executar Missão do Enxame (Web + Mkt + Social + Prompts)	Terminal swarm.bat ou PowerShell	Maestro LongCat + Flash Specialists	~\$0.005 / rodada
Análise de Imagens / Prints no Terminal	Kimi Code CLI (kimi)	/model kimi-k3 ou kimi-k2.7-code	Consome cota Go (\$1.00-\$3.00/1M)
Desenvolvimento de Código Complexo / Pair Programming	Antigravity Desktop / IDE	Gemini 2.5 Pro / Flash	Incluso na conta Google
Automações de Longa Duração & Scripts em Background	Terminal / server.js	longcat-2.5-preview-free	\$0.00 (ilimitado)

6. Matemática do Prompt Caching (98% de Desconto)

CENÁRIO OPERACIONAL	TOKENS PROCESSADOS	CUSTO SEM CACHE	CUSTO COM CACHE ATIVO
1 Chamada com System Prompt	35.000 tokens de entrada	\$0.00525	\$0.000105
100 Chamadas do Enxame	3.500.000 tokens de entrada	\$0.52500	\$0.01050 (1 centavo!)
1.000 Chamadas no Mês	35.000.000 tokens de entrada	\$5.25000	\$0.10500 (10 centavos!)